

VERİ BİLİMİ PROJE RAPORU LA LIGA FUTBOL İSTATİSTİKLERİ ANALİZİ VE TAHMİNLEME

Hazırlayanlar:

Taha SEYMEN - 1306240024

Mahmud KERİM - 1306230004

Problem Tanımı

Avrupa'nın beş büyük ligindeki takımların istatistiklerini içeren veri setinden yola çıkarak, İspanya La Liga'nın 2010-2011 ile 2018-2019 sezonları arasındaki futbol istatistiklerini analiz etmektir. Temel amaç, takımların isabetli şut, atılan gol, yenilen gol ve toplanan puan gibi performans metrikleri arasındaki ilişkileri ortaya çıkarmak ve bu istatistiksel verileri kullanarak takımların sezon sonu toplayacağı puanı tahmin edebilen bir makine öğrenmesi modeli geliştirmektir. Söz konusu model, takımların sezon sonu toplayacağı puanı tahmin etmeyi hedeflemektedir.

Kullanılan Veri Seti ve Kaynağı

Projede Avrupa'nın 5 büyük ligine ait takım istatistiklerini içeren "Inside Top 5 Football Leagues" isimli ham veri seti kullanılmıştır. Bu veri seti; İngiltere Premier Ligi, İspanya La Liga, Almanya Bundesliga, İtalya Serie A ve Fransa Ligue 1 liglerindeki takımların sezonluk istatistiksel verilerini kapsamaktadır.

İlgili veri seti açık erişim lisansına (Open Access) sahip olup Kaggle platformundan temin edilmiştir (Dosya Adı: 'Big 5 European football leagues teams stats.csv'). Kaynak URL: <https://www.kaggle.com/code/ukaszkwestarz/inside-top-5-football-leagues/input>

Yöntem

Projenin geliştirilme sürecinde veri manipülasyonu, görselleştirme ve yapay zeka modellemesi için Python programlama dili (Pandas, Matplotlib, Seaborn ve Scikit-learn kütüphaneleri) kullanılmıştır.

Kütüphane	Kullanım Amacı
pandas	Veri setinin yüklenmesi, La Liga'ya özel filtrelenmesi, eksik verilerin temizlenmesi ve yeni özelliklerin (Feature Engineering) üretilmesi
matplotlib	Temel grafik çizimleri ve görselleştirme altyapısı
seaborn	Dağılım Grafiği (Scatter), Çubuk Grafiği (Bar), Histogram ve Korelasyon Isı Haritası (Heatmap) çizimleri
scikit-learn	Çoklu Doğrusal Regresyon modelinin kurulması, eğitim/test bölünmesi ve R-kare doğruluk skoru hesabı

- **Veri Ön İşleme ve Temizleme:** Veri setinden sadece 'La Liga' takımları ve 2010-2019 yılları arasındaki 9 sezon filtrelenmiştir. 'notes' gibi eksik verisi (NaN) çok olan gereksiz sütunlar düşürülmüş (drop), 'cards_yellow' ve 'cards_red' gibi eksik veriler 0 ile doldurulmuştur (imputation). Sonrasında float olan bu veri tipleri tamsayıya (int) dönüştürülmüştür.
- **Keşifçi Veri Analizi (EDA) ve Görselleştirme:** Değişkenler arası ilişkiyi anlamlandırmak adına Dağılım Grafiği (Scatter Plot), Çubuk Grafiği (Bar Chart), Histogram ve Korelasyon Isı Haritası (Heatmap) gibi çizimler yapılmıştır.
- **Özellik Mühendisliği (Feature Engineering):** Takımların hücum/savunma dengesini ölçmek için atılan ('goals_for') ve yenilen gol ('goals_against') verileri kullanılarak 'goal_ratio' (gol oranı) isimli yepyeni bir değişken oluşturulmuştur.
- **Makine Öğrenmesi ile Modelleme:** Atılan ve yenilen gol sayısı bağımsız değişken, sezon sonu toplanan puan ('points') ise bağımlı değişken olarak seçilerek 'Çoklu Doğrusal Regresyon (Multiple Linear Regression)' modeli kurulmuş, veri eğitim/test olarak ayrılmış ve R-kare skoru ile başarı durumu hesaplanmıştır.

Bulgular

- Veri seti üzerinde yapılan görsel analizlerde (Dağılım Grafiği), isabetli şut sayısı ('shots_on_target') ile atılan gol sayısı ('goals_for') arasında pozitif ve güçlü bir ilişki olduğu saptanmıştır.
- Çıkarılan Korelasyon Isı Haritası (Heatmap) neticesinde; takımların topladığı puan, galibiyet sayısı, atılan gol ve yenilen gol değerlerinin birbirleriyle çok yüksek derecede anlamlı bir ilişkiye sahip olduğu görülmüştür.
- Çoklu Doğrusal Regresyon ile kurulan modelin, takımların sezon sonu toplayacakları puanı başarılı bir doğruluk skoru (R-kare) ile tahmin edebildiği doğrulanmıştır.
- Gruplandırma yapılarak hazırlanan dokuz sezonluk istatistiksel özet tablosunda; sezon başına düşen ortalama puan ve gol oranlarına göre Barcelona ve Real Madrid gibi takımların ligin en başarılı 5 takımı listesinde zirveyi paylaştığı istatistiksel olarak gözlemlenmiştir.

Sınırlamalar

- Yapılan bu istatistiksel analiz sadece İspanya La Liga'yı ve belirli bir zaman aralığını (2010-2019) kapsadığı için elde edilen bulgular, futbolun taktiksel olarak evrildiği günümüz sezonlarına veya Premier Lig, Serie A gibi farklı dinamiklere sahip liglere doğrudan genellenemez.
- Orijinal veri setindeki bazı sütunlarda ('games_complete', 'unused_subs', 'notes') aşırı yüksek oranda eksik (NaN) değerlerin bulunması, ilgili özniteliklerin analizden mecburen çıkartılmasına neden olmuş ve analiz edilebilir veri çeşitliliğini kısıtlamıştır.
- Kurulan regresyon modeli sadece atılan ve yenilen gol sayılarına dayalı basit ve matematiksel bir tahminde bulunmaktadır. Futbolda sezon sonu puanını doğrudan etkileyebilecek topla oynama yüzdesi, xG (Gol Beklentisi), bütçe, sakatlıklar ve teknik direktör değişiklikleri gibi çok daha kapsamlı faktörler bu çalışmanın veri setinde bulunmadığından modele dahil edilememiştir.

Öğrenilenler

- Veri temizleme ve ön işlemenin (imputation, eksik verilerin drop edilmesi ve veri tipi dönüşümleri) modelin eğitim kalitesini ve veri bilimi projelerinin doğruluğunu doğrudan belirleyen en kritik adım olduğu tecrübe edilmiştir.
- Orijinal veri setinde bulunmayan ancak mevcut sütunlardan türetilen yeni metriklerin (Feature Engineering - Örn: Gol oranı), analizlerin gücünü artırmadaki katkısı görülmüştür.
- Pandas kütüphanesi kullanılarak büyük ve karmaşık bir CSV dosyasının filtrelenmiş net bir proje verisi (DataFrame) haline getirilmesi, Matplotlib ve Seaborn kütüphaneleriyle ise istatistiksel bilgilerin anlamlı içgörü sağlayan grafiklere (Heatmap, Scatter) dönüştürülmesi pratiği pekiştirilmiştir.
- Scikit-learn kütüphanesi üzerinden denetimli bir makine öğrenmesi uygulaması (Çoklu Doğrusal Regresyon) kurarak, spor istatistikleri üzerinde sonuç tahminleme (prediction) süreçlerinin nasıl gerçekleştirildiği ve R-kare doğruluk skorunun nasıl yorumlanacağı öğrenilmiştir.

Kaynakça

- Kaggle — "Inside Top 5 Football Leagues" veri seti. Erişim: <https://www.kaggle.com/code/ukaszkwestarz/inside-top-5-football-leagues/input>
- Pandas Documentation — <https://pandas.pydata.org/docs/>
- Scikit-learn Documentation — <https://scikit-learn.org/stable/>
- Matplotlib Documentation — <https://matplotlib.org/stable/>
- Seaborn Documentation — <https://seaborn.pydata.org/>